



人工智能原理


第22章 – 强化学习

彭振辉

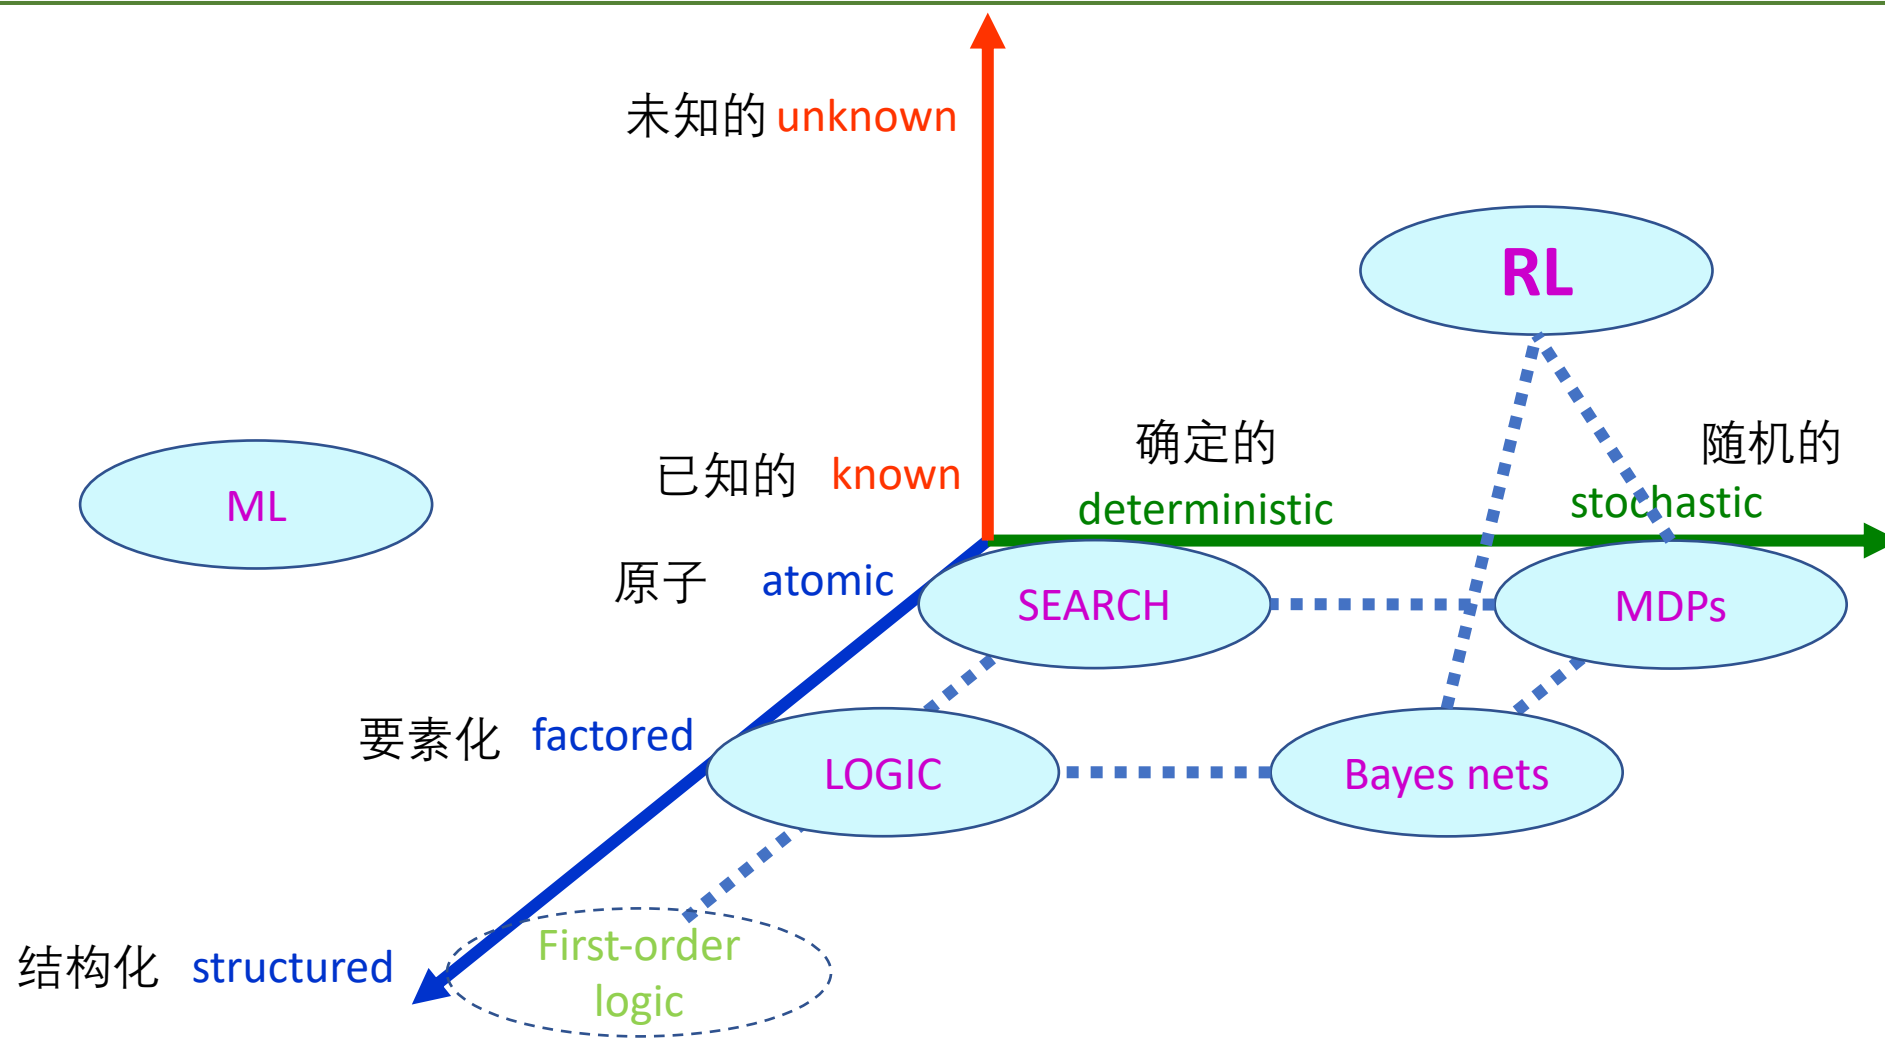
中山大学人工智能学院

2024年春季学期

Reinforcement Learning



Reinforcement Learning






- 被动强化学习
 - Model-based
 - 自适应动态规划
 - Model-free
 - 直接效用估计
 - 时序差分学习
- 主动强化学习
 - Exploration 和 Exploitation
 - Q-learning
 - Approximate Q-learning
- 22.5 – 22.7为课外阅读

神秘难懂的强化学习?
原理很简单!

回顾：马尔科夫决策过程



- An MDP is defined by:
 - A **set of states** 状态 $s \in S$
 - A **set of actions** 行动 $a \in A$
 - A **transition model** 转移模型 $T(s, a, s')$
 - Probability that a from s leads to s' , i.e., $P(s' | s, a)$
 - A **reward function** 回报/奖励函数 $R(s, a, s')$ for each transition
 - A **start state** 初始状态
 - Possibly a **terminal state** 终止状态 (or **absorbing** state)
 - **Utility function** which is additive (discounted) rewards



- MDPs are **fully observable** but probabilistic search problems

课程回顾 : Value Iteration 价值迭代




- 从 $U_0(s) = 0$ 和一些终止参数 ϵ 开始
- 重复迭代直到收敛 (即, 直到所有更新小于 ϵ)
 - 对每个状态做一个贝尔曼更新 (本质上是一个 expectimax 层) :



$$U_{k+1}(s) \leftarrow \max_a \sum_{s'} P(s' | a, s) [R(s, a, s') + \gamma U_k(s')]]$$

$$V_{k+1}(s) \leftarrow \max_a \underbrace{\sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V_k(s')]}_{Q_k(s, a)}$$

- 定理 : 将收敛到唯一的最优值
- 每次迭代的运行时间?
 - 每次迭代的复杂度: $O(S^2A)$



价值迭代计算案例



s	a	s'	$T(s, a, s')$	$R(s, a, s')$
A	0	A	0.50	2.0
A	0	B	0.50	-1.0
A	1	A	0.50	1.0
A	1	B	0.50	2.0
B	0	A	0.0	-2.0
B	0	B	1.0	-1.0
B	1	A	0.10	-3.0
B	1	B	0.90	-1.0



初始 $V_0=0$; 折扣因子 $\gamma=1$
 试着求左图各个值, 比如

$V_1(A)$

$V_1(B)$

价值迭代计算案例

Value Iteration



s	a	s'	$T(s, a, s')$	$R(s, a, s')$
A	0	A	0.50	2.0
A	0	B	0.50	-1.0
A	1	A	0.50	1.0
A	1	B	0.50	2.0
B	0	A	0.0	-2.0
B	0	B	1.0	-1.0
B	1	A	0.10	-3.0
B	1	B	0.90	-1.0

$$0.1 * (-3.0 + 1.5) + 0.9 * (-1.0) \neq (-1.0)$$



- 仍然假设一个马尔可夫决策过程(MDP):

- A set of states 状态 $s \in S$
- A set of actions 行动 (per state) A
- A model $T(s,a,s')$ 转移模型
- A reward function $R(s,a,s')$ 回报函数

- 仍然想要求解一个策略 policy $\pi(s)$



- 新的情况：**不知道 T 或 R**


- I.e. 我们不知道哪些状态是好的或行动的后果是什么
- 必须实际尝试行动和状态去学习
- Note: 不知道的事物，并不代表它们不存在，去学习！



Basic ideas:

- **Exploration 探索**: 你必须 **尝试未知的行动** 才能获取信息
- **Exploitation 利用 (信息)**: 最终, 你必须使用你所知道的信息
- **Sampling 采样**: 你可能需要重复多次才能获得良好的估计
- **Generalization 泛化**: 你在一个状态学到的东西也可能适用于其它状态

Reinforcement Learning




- Basic idea:
 - 以**回报(rewards)**的形式接收反馈
 - Agent 的效用由回报函数定义
 - 必须（学会）采取行动以**最大化期望回报(maximize expected rewards)**
 - 所有的学习都是基于观察到的结果样本！

The Real Crawler!



The Crawler!



DeepMind Atari



Learning to Walk



Initial

[Kohl and Stone, ICRA 2004]


Learning to Walk



Finished

[Kohl and Stone, ICRA 2004]

Offline (MDPs) vs. Online (RL)



Offline Solution

Agent拥有环境的完整模型，并且知道回报函数



Online Learning

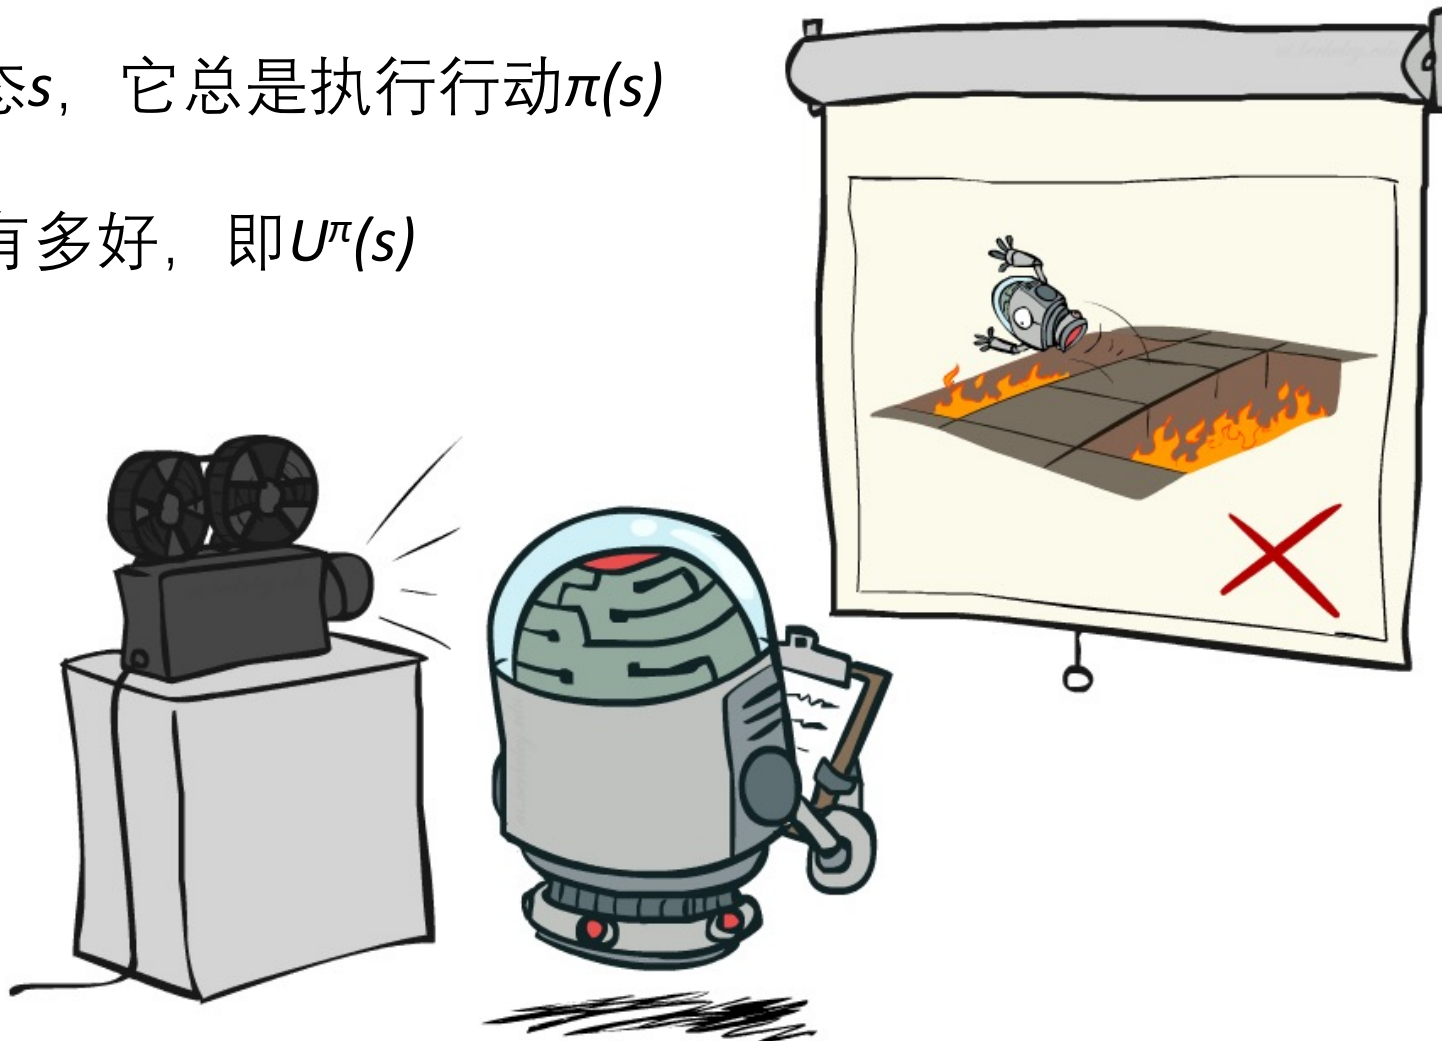
Agent没有关于两者的先验知识

Passive Reinforcement Learning 被动强化学习




Agent的策略 π 是固定的：在状态 s ，它总是执行行动 $\pi(s)$

其目标只是简单地学习该策略有多好，即 $U^\pi(s)$




Passive Reinforcement Learning

- 简化的任务：策略评估 policy evaluation
 - 输入：固定的策略 $\pi(s)$
 - 你不知道转移模型 $T(s,a,s')$
 - 你不知道回报 $R(s,a,s')$
 - 目标：学习状态值
- 在这种情况下：
 - 学习者“随心所欲”
 - 无法选择采取什么行动
 - 只需执行策略并吸取经验
 - 这不是离线规划！你实际上在世界上采取了行动



Model-Based Learning




- Model-Based Idea:
 - 根据经历学习近似的模型
 - 求解学习到的 MDP
- 第 1 步：根据经历学习MDP 模型
 - 计算每个 s, a 的结果 s'
 - 归一化以估计 $\hat{T}(s, a, s')$
 - 当我们经历 (s, a, s') 时发现每一个 $\hat{R}(s, a, s')$
- 第 2 步：求解学习到的 MDP
 - 例如，像以前一样使用 value iteration



Example: Model-Based Learning

Input Policy π



Assume: $\gamma = 1$

Observed Episodes (Training)

Episode 1

B, east, C, -1
C, east, D, -1
D, exit, x, +10

Episode 2

B, east, C, -1
C, east, D, -1
D, exit, x, +10

Episode 3

E, north, C, -1
C, east, D, -1
D, exit, x, +10

Episode 4

E, north, C, -1
C, east, A, -1
A, exit, x, -10

Learned Model

$$\hat{T}(s, a, s')$$


T(B, east, C) =
T(C, east, D) =
T(C, east, A) =
...

$$\hat{R}(s, a, s')$$

R(B, east, C) =
R(C, east, D) =
R(D, exit, x) =
...

Example: Model-Based Learning

Input Policy π



Assume: $\gamma = 1$

Observed Episodes (Training)

Episode 1

B, east, C, -1
C, east, D, -1
D, exit, x, +10

Episode 2

B, east, C, -1
C, east, D, -1
D, exit, x, +10

Episode 3

E, north, C, -1
C, east, D, -1
D, exit, x, +10

Episode 4

E, north, C, -1
C, east, A, -1
A, exit, x, -10

Learned Model

$$\hat{T}(s, a, s')$$

T(B, east, C) = 1.00
T(C, east, D) = 0.75
T(C, east, A) = 0.25
...

$$\hat{R}(s, a, s')$$

R(B, east, C) = -1
R(C, east, D) = -1
R(D, exit, x) = +10
...

Pros and cons



- Pro:
 - 有效地利用了经历
- Con:
 - 可能无法扩展到大型状态空间
 - 一次学习一个状态-动作对模型
 - 无法解决 $|S|$ 非常大的 MDP



类比例子: 期望年龄

目标：计算 人工智能原理课 学生的期望年龄

已知 $P(A)$ 的情况

$$E[A] = \sum_a P(a) \cdot a = 0.35 \times 20 + \dots$$

未知 $P(A)$ 时, 收集样本 $[a_1, a_2, \dots a_N]$

未知 $P(A)$: “Model Based”

$$\hat{P}(a) = \frac{\text{num}(a)}{N}$$

$$E[A] \approx \sum_a \hat{P}(a) \cdot a$$


为什么这行得通？
因为最终你会学习到正确的模型。

未知 $P(A)$: “Model Free”

$$E[A] \approx \frac{1}{N} \sum_i a_i$$

为什么这行得通？
因为样本以正确的频率出现。

Model-Free Learning



Direct Evaluation 直接(效用)估计




- 目标：计算 π 下每个状态的（效用）值
- idea：平均化观察到的样本值
 - 按 π 行动
 - 每次访问一个状态时，写下折扣回报的总和是多少
 - 取这些样本的折扣回报平均值
- 这称为直接（效用）估计



Example: Direct Evaluation

Input Policy π



Assume: $\gamma = 1$

Observed Episodes (Training)

Episode 1

B, east, C, -1
C, east, D, -1
D, exit, x, +10

Episode 2

B, east, C, -1
C, east, D, -1
D, exit, x, +10


Episode 3

E, north, C, -1
C, east, D, -1
D, exit, x, +10

Episode 4


E, north, C, -1
C, east, A, -1
A, exit, x, -10

Output Values



Example: Direct Evaluation

Input Policy π



Assume: $\gamma = 1$

Observed Episodes (Training)

Episode 1

B, east, C, -1
C, east, D, -1
D, exit, x, +10

Episode 2

B, east, C, -1
C, east, D, -1
D, exit, x, +10

Episode 3

E, north, C, -1
C, east, D, -1
D, exit, x, +10

Episode 4


E, north, C, -1
C, east, A, -1
A, exit, x, -10

Output Values

	-10 A	
+8 B	+4 C	+10 D
	-2 E	

Quiz: Direct Evaluation

Input Policy π



What if $\gamma = 0.5$?

Observed Episodes (Training)

Episode 1

B, east, C, -1
C, east, D, -1
D, exit, x, +10

Episode 2

B, east, C, -1
C, east, D, -1
D, exit, x, +10


Episode 3

E, north, C, -1
C, east, D, -1
D, exit, x, +10

Episode 4

E, north, C, -1
C, east, A, -1
A, exit, x, -10

Output Values





直接效用估计的好处和问题

- 好处
 - 很容易理解
 - 它不需要任何关于 T、R 的知识
 - 它使用样本中体现的转换关系，最终 (大样本下) 能计算正确的平均效用值
- 问题
 - 得等到一次经历(episode)完成才能学习
 - 浪费了有关状态与状态之间的信息
 - 每个状态都必须分开学习
 - 所以学起来需要很长时间
 - 思考：所以为什么学习起来需要很长时间？怎么办呢？

忽略了C→D, C→A的转移概率，上上页的例子中，恰好是从E出发的那次经历最后到达了A，得到-10。


Output Values

	-10 A	
+8 B	+4 C	+10 D
	-2 E	

If B and E both go to C under this policy, how can their values be different?

*E.g., B=at home, study hard
E=at library, study hard
C=know material, go to exam*

Temporal difference (TD) learning 时序差分学习




策略迭代？

- 简化的 Bellman 更新计算**固定策略**的 V :
 - 每一轮，用 V 上的一步前瞻(one-step-look-ahead)层替换 V

$$V_0^\pi(s) = 0$$

$$V_{k+1}^\pi(s) \leftarrow \sum_{s'} T(s, \pi(s), s') [R(s, \pi(s), s') + \gamma V_k^\pi(s')]$$

- 这种方法充分利用了状态之间的联系
- 不幸的是，我们需要 T 和 R 来做到这一点！
- 关键问题：我们如何在不知道 T 和 R 的情况下对 V 进行更新？
 - 在model-free的思想下，我们如何在不知道权重的情况下取加权平均值？



TD as approximate Bellman update

- 我们想通过计算一些平均值来改进我们对 V 的估计:

$$V_{k+1}^{\pi}(s) \leftarrow \sum_{s'} T(s, \pi(s), s') [R(s, \pi(s), s') + \gamma V_k^{\pi}(s')]$$

- Idea 1: 对结果 s' 进行采样 (通过执行行动!) 并取平均值



$$sample_1 = R(s, \pi(s), s'_1) + \gamma V_k^{\pi}(s'_1)$$

$$sample_2 = R(s, \pi(s), s'_2) + \gamma V_k^{\pi}(s'_2)$$

...

$$sample_n = R(s, \pi(s), s'_n) + \gamma V_k^{\pi}(s'_n)$$


$$V_{k+1}^{\pi}(s) \leftarrow \frac{1}{n} \sum_i sample_i$$



Almost! But we can't rewind time to get sample after sample from state s .
我们在尝试时, 不能重复回到状态 s 去尝试

TD as approximate Bellman update

- Idea 2: Update value of s after each transition s, a, s', r :
 - Update $V^\pi([3,1])$ based on $R([3,1], \text{up}, [3,2])$ and $\gamma V^\pi([3,2])$
 - Update $V^\pi([3,2])$ based on $R([3,2], \text{up}, [3,3])$ and $\gamma V^\pi([3,3])$
 - Update $V^\pi([3,3])$ based on $R([3,3], \text{right}, [4,3])$ and $\gamma V^\pi([4,3])$
- Idea 3: Update values by maintaining a *running average*





Running Averages

- How do you compute the average of 1, 4, 7?
- Method 1: add them up and divide by N
 - $1+4+7 = 12$
 - $\text{average} = 12/N = 12/3 = 4$
- Method 2: keep a running average μ_n and a running count n
 - $n=0 \quad \mu_0=0$
 - $n=1 \quad \mu_1 = (0 \cdot \mu_0 + x_1)/1 = (0 \cdot 0 + 1)/1 = 1$
 - $n=2 \quad \mu_2 = (1 \cdot \mu_1 + x_2)/2 = (1 \cdot 1 + 4)/2 = 2.5$
 - $n=3 \quad \mu_3 = (2 \cdot \mu_2 + x_3)/3 = (2 \cdot 2.5 + 7)/3 = 4$
 - General formula: $\mu_n = ((n-1) \cdot \mu_{n-1} + x_n)/n$
 $= [(n-1)/n] \mu_{n-1} + [1/n] x_n$ (weighted average of old mean, new sample)

两个权重值有什么联系?

它们都随 n 的变化而变化，每次都要新算一个值，有没有简化方法?

Running Averages



- What if we use a weighted average with a fixed weight?
 - $\mu_n = (1-\alpha) \mu_{n-1} + \alpha x_n$
 - $n=1 \quad \mu_1 = x_1$
 - $n=2 \quad \mu_2 = (1-\alpha) \cdot \mu_1 + \alpha x_2 = (1-\alpha) \cdot x_1 + \alpha x_2$
 - $n=3 \quad \mu_3 = (1-\alpha) \cdot \mu_2 + \alpha x_3 = (1-\alpha)^2 \cdot x_1 + \alpha(1-\alpha)x_2 + \alpha x_3$
 - $n=4 \quad \mu_4 = (1-\alpha) \cdot \mu_3 + \alpha x_4 = (1-\alpha)^3 \cdot x_1 + \alpha(1-\alpha)^2 x_2 + \alpha(1-\alpha)x_3 + \alpha x_4$
- 早期的x值在当前时间点，会发生什么变化？
- I.e., **exponential forgetting** of old values
- 拓展：
 - μ_n is a convex combination^[1] of sample values (weights sum to 1)
 - $E[\mu_n]$ is a convex combination of $E[X_i]$ values, hence unbiased

[1] 凸组合 <https://baike.baidu.com/item/%E5%87%B8%E7%BB%84%E5%90%88/18999826>

TD as approximate Bellman update




- Idea 3: Update values by maintaining a **running average**
- $\text{sample} = R(s, \pi(s), s') + \gamma V^\pi(s')$
- $V^\pi(s) \leftarrow (1-\alpha) \cdot V^\pi(s) + \alpha \cdot \text{sample}$
- $V^\pi(s) \leftarrow V^\pi(s) + \alpha \cdot [\text{sample} - V^\pi(s)]$
- This is the **temporal difference learning rule**
时序差分
- $[\text{sample} - V^\pi(s)]$ is the “TD error”
- α is the **learning rate** 学习率
- I.e., observe a sample, move $V^\pi(s)$ a little bit to make it more consistent with its neighbor $V^\pi(s')$



Temporal Difference Learning 时序差分学习

Note: 人也一样！

- Big idea: 从每一次状态转移中学习！
 - 我们每经历一次状态转移 (s, a, s', r) ，更新一次 $V(s)$
 - 越可能的转移结果 s' 将越频繁地参与到更新中
- 状态值的时序差分学习
 - 状态还是固定的，同样也是做状态评估！
 - 将效用估计朝着理想均衡的方向调整
 - α 作为学习速度参数，随某个状态被访问次数的增加而递减，状态值函数能收敛



Sample of $V(s)$: $sample = R(s, \pi(s), s') + \gamma V^\pi(s')$

Update to $V(s)$: $V^\pi(s) \leftarrow (1 - \alpha)V^\pi(s) + (\alpha)sample$

Same update: $V^\pi(s) \leftarrow V^\pi(s) + \alpha(sample - V^\pi(s))$

Temporal Difference Learning 时序差分学习



function PASSIVE-TD-LEARNER(*percept*) **returns** 一个动作
 inputs: *percept*, 指示当前状态 s' 与奖励信号 r 的某个感知
 persistent: π , 一个确定性策略
 s , 之前的状态, 初始为空
 U , 关于状态效用的表, 初始化为空
 N_s , 关于状态出现频率的表, 初始为零

 if s' 是一个新的状态 **then** $U[s'] \leftarrow 0$
 if s 非空 **then**
 增加 $N_s[s]$
 $U[s] \leftarrow U[s] + \alpha(N_s[s]) \times (r + \gamma U[s'] - U[s])$
 $s \leftarrow s'$
 return $\pi[s']$

图22-4 一种使用时序差分方法学习效用估计的被动强化学习智能体。我们选择适当的步长函数 $\alpha(n)$ 以确保收敛

例子: 时序差分学习

States

	A	
B	C	D
	E	

Assume: $\gamma = 1$,
 $\alpha = 1/2$

Observed Transitions

B, east, C, -2

	0	
0	0	8
	0	

C, east, D, -2

	0	
-1	0	8
	0	

	0	
-1	3	8
	0	

$$V^\pi(s) \leftarrow (1 - \alpha)V^\pi(s) + \alpha [R(s, \pi(s), s') + \gamma V^\pi(s')]$$

$$V^\pi(s) \leftarrow V^\pi(s) + \alpha(\text{sample} - V^\pi(s))$$

Problems with TD Value Learning

- TD 价值学习是一种无模型(model-free)的策略评估方法，通过运行样本获得的状态值的平均值模拟贝尔曼更新
- 但是，如果我们想将价值转变为（新的）策略，我们就会遇到问题：

$$\pi(s) = \arg \max_a Q(s, a)$$

$$Q(s, a) = \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V(s')]$$

- 我们不知道 T 和 R!
- 应对方法: 学习 Q-values (Q值), 而不是 values (效用值)
- 让行动选择也变得无模型

